

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное
учреждение высшего образования
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Компьютерные науки и анализ данных»

ОТЧЁТ О КОМАНДНОМ ПРОГРАММНОМ ПРОЕКТЕ

на тему:

**LLM Web Parsing — сервис автоматизированной разметки веб-страниц на
основе больших языковых моделей
(итоговый отчёт)**

Выполнили студенты группы #КНАД242, 2 курс:

Широкая Анна Антоновна

Беляев Даниил Андреевич

Копейкин Михаил Александрович

Принял руководитель проекта:

Козловский Виктор Евгеньевич

Старший разработчик, X5 Tech

Москва, 2026

Аннотация

Курсовой проект — это парсер интернет-магазинов, который сам придумывает CSS-селекторы вместо человека. По одной странице товара сервис обращается к большой языковой модели и сохраняет селекторы для имени, цены, артикула и картинки. Дальше эти селекторы применяются ко всем остальным URL того же домена уже без LLM — получается быстро и почти бесплатно. Главная идея — никаких жёстких правил под конкретный магазин: сервис работает с любым e-commerce сайтом из коробки.

В качестве модели используем Llama 3.1 8B Instruct через бесплатный Inference API Hugging Face. Опционально подключается GPT-4o-mini от OpenAI — он чуть точнее, особенно на сложных страницах. На финальном этапе руководитель попросил расширить функциональность: теперь сервис не только читает страницу, но и нажимает кнопки — «Добавить в корзину», «Купить», переходы между карточками. Поиск кнопок построен на эвристическом скоринге (текст, aria-label, класс, role) с поддержкой четырёх языков, а если эвристика сомневается — спрашиваем LLM.

Бекенд написан на FastAPI, валидация — Pydantic v2, хранилище — SQLite через aiosqlite. На тесты ушло около двух недель: 139 автотестов в 10 модулях, прогоняются за секунду. Проект собран в Docker и выложен в открытый репозиторий на GitHub.

Ключевые слова

веб-парсинг, LLM, CSS-селекторы, TOON, Llama 3.1, GPT-4o-mini, Playwright, FastAPI, browser automation, интерактивные действия, интернет-магазины, headless Chromium, антибот-защита, playwright-stealth, эвристический скоринг, LangChain, Pydantic.

Содержание

Чтобы собрать оглавление, откройте файл в Microsoft Word и выполните: «Ссылки» → «Оглавление» → «Автособираемое оглавление». Все заголовки в документе размечены стилями Heading 1, Heading 2 и Heading 3 — Word подтянет их сам.