

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное
учреждение высшего образования
**«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Факультет компьютерных наук
Образовательная программа «Компьютерные науки и анализ данных»

ОТЧЁТ О КОМАНДНОМ ПРОГРАММНОМ ПРОЕКТЕ

на тему:

**LLM Web Parsing — сервис автоматизированной разметки веб-страниц на
основе больших языковых моделей
(итоговый отчёт)**

Выполнили студенты группы #КНАД242, 2 курс:

Широкая Анна Антоновна

Беляев Даниил Андреевич

Копейкин Михаил Александрович

Принял руководитель проекта:

Козловский Виктор Евгеньевич

Старший разработчик, X5 Tech

Москва, 2026

Аннотация

В отчёте представлены итоговые результаты разработки AI-сервиса автоматизированной разметки веб-страниц LLM Web Parsing. Проект реализует постановку задачи Parsmart: по образцу страницы товара сервис автоматически подбирает CSS-селекторы для всех её ключевых полей (название, цена, артикул, изображение) и позволяет переиспользовать эти селекторы на тысячах страниц того же домена без повторного обращения к языковой модели. Ключевая ценность решения — универсальность: оно работает с любым e-commerce сайтом без необходимости программировать отдельные правила извлечения под каждый магазин.

Разработанная система применяет большие языковые модели Llama 3.1 8B Instruct и GPT-4o-mini для семантического понимания HTML-разметки. Это позволяет автоматически идентифицировать расположение ключевых элементов даже на ранее не встречавшихся страницах. На итоговом этапе по требованию заказчика реализована функция интерактивных действий — система не только читает страницу, но и взаимодействует с ней: нажимает кнопки, добавляет товары в корзину, переходит между карточками. Поиск интерактивных элементов выполняется через эвристическую систему скоринга (с поддержкой русского, английского, французского и немецкого языков) с автоматическим LLM-fallback при низкой уверенности эвристики.

Архитектура реализована на FastAPI с поддержкой асинхронной обработки, валидацией через Pydantic, асинхронным доступом к базе данных SQLite через aiosqlite, интеграцией LangChain и Playwright. Покрывание тестами — 139 автоматизированных тестов в 10 модулях. Система контейнеризирована через Docker и доступна в публичном репозитории на GitHub.

Ключевые слова

веб-парсинг, большие языковые модели, LLM, автоматизированная разметка, CSS-селекторы, TOON, Hugging Face, Llama, GPT-4o-mini, Playwright, FastAPI, browser automation,